

Expressões  
Regulares



AMONTADA VALLEY

# Introdução




# Definições

- Basicamente, podemos dizer algo abrangente de forma específica. Definindo um padrão de busca, temos uma lista de possibilidades.
- “Como o brinquedo LEGO, várias pecinhas diferentes, cada uma com sua característica, que juntas compõem estruturas completas e podem ser arranjadas com infinitas combinações diferentes.”
- Expressões Regulares são metacaracteres que casam um padrão. É uma maneira de procurar um texto especificando padrões.
- Padrões para validar data, horário, número IP, e-mail, RG, CPF, telefones... Exemplo: ER para números de telefones =>  $([0-9]\{2\})? [0-9]\{4\}-[0-9]\{4\}$ . Casa qualquer uma das strings: “83 3224-1063”, “83 3254-3421”, “82 2343-1212”...

# História


- O termo deriva do que se chamou de álgebra de conjuntos regulares (*“regular sets”*), do matemático Stephen Cole Kleene.
- 1968, Ken Thompson implementava no *qed* um comando de contexto que aceitava expressões regulares. Sua sintaxe? *g/RE/p* (Global Regular Expression Print)... Mais tarde deu origem ao famoso *grep* nos sistemas Unix.
- 1986, criado um pacote pioneiro em C, chamado *regex* e de graça! Daí a norma IEEE POSIX 1003.2 (POSIX.2) padroniza expressões regulares.

# Os Metacaracteres



# Sopa de letrinhas

Metacaractere	Nome
.	Ponto
[ ]	Lista
[^]	Lista negada
?	Opcional
*	Asterisco
+	Mais
{ }	Chaves



Metacaractere	Nome
^	Circunflexo
\$	Cifrão
\b	Borda
\	Escape
	Ou (pipe)
( )	Grupo
\1	Retrovisor

# Sopa de letrinhas – exemplos

**Miller, Miler, Müller, Müller, Mueler, Mueller:**

`M(ü|i|ue)ll?er`

**Siglas de 4 letras, começando com UF:**

`UF[A-Z]{2}`

**Tags HTML `<b>`, `</b>`, `<i>`, `</i>`, `<u>`, `</u>`:**

`</?[BbUuli]>`

**Títulos (primeira linha não pontuada):**

`^[A-Za-z0-9 ]+$`

**Palavras:**

`\b[A-Za-z]+\b`

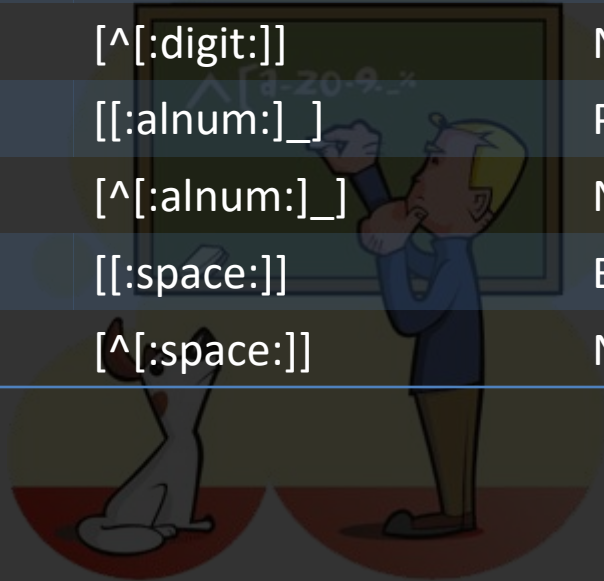
# Padrões POSIX

Classe POSIX	Similar	Significa
[ :upper:]	[A-Z]	Letras maiúsculas
[ :lower:]	[a-z]	Letras minúsculas
[ :alpha:]	[A-Za-z]	Maiúsculas/Minúsculas
[ :alnum:]	[A-Za-z0-9]	Letras e números
[ :digit:]	[0-9]	Números
[ :xdigit:]	[0-9A-Fa-f]	Números Hexadecimais
[ :punct:]	[.,!?:...]	Sinais de pontuação
[ :blank:]	[ \t]	Espaço e TAB
[ :space:]	[ \t\n\r\f\v]	Caracteres brancos



# (Alguns m | M)etacaracteres tipo barra-letra

Classe POSIX	Similar	Significa
\d	[:digit:]	Dígito
\D	^[[:digit:]]	Não-dígito
\w	[:alnum:]_	Palavra
\W	^[[:alnum:]_]	Não-palavra
\s	[:space:]	Branco
\S	^[[:space:]]	Não-branco



# Editores de texto e Linguagens



# Observações

- Não há classes do POSIX e não suporta acentuação.
- Solução? [A-Za-zÀ-u]
- Quebras de linha e parágrafos podem ser identificados com `\n`, assim as ERs podem casar múltiplas linhas de uma vez.

A spiral-bound notebook with lined pages is shown at an angle. A silver pen with a black grip and an orange pencil are resting on the pages. The notebook's spiral binding is visible on the left side.

# Editores de texto de Linguagens

JavaScript, Python, PHP, Java e outras.



## Linguagens de Programação

- Na J2SE aparecem no pacote `java.util.regex`, além de algumas melhorias na classe `java.lang.String`.
- No Python deve ser criado um `"import re"` para utilizar ReGex nos códigos.
- No PHP e JavaScript são métodos nativos, não necessitam de nada especial para utilização.
- No Javascript são baseadas em dois elementos: um padrão e outro o modificador. A syntax é bastante simples `/padrão/modificador`. `/Valley/i` por exemplo pode ser utilizada para encontrar a palavra "valley" e a letra "i" indica que não precisa se preocupar com maiúsculas e minúscula.

# Exemplos

Data (dd/mm/aaaa)

[0-9]{2}/[0-9]{2}/[0-9]{4}

[0123][0-9]/[01][0-9]/[12][0-9]{3}

([012][0-9]|3[0-1])/([0[0-9]|1[012])/[12][0-9]{3}

(0[1-9]|[12][0-9]|3[01])/0[0-9]|1[012])/[12][0-9]{3}

Horário (hh:mm)

[0-9]{2}:[0-9]{2}

[012][0-9]:[0-5][0-9]

([01][0-9]|2[0-3]):[0-5][0-9]

Email (email@company.com)

[^@]+@[^@]+\.[\*]

[A-Za-z0-9\_.-]+@[A-Za-z0-9\_]+\.[a-z]+

[A-Za-z0-9\_.-]+@[A-Za-z0-9\_]+\.[a-z]{2,3}

## Bibliografia

Jargas, Aurélio Marinho. **Expressões Regulares**: Uma abordagem divertida. Ed. Novatec, 3ª edição. São Paulo, 2009.

## Referências

**Blog do Autor do livro Expressões Regulares:**

<http://aurelio.wordpress.com/2009/07/17/10anos-expressoes-regulares/>

**Site oficial do livro Expressões Regulares:** <http://www.piazinho.com.br/>

**Expressão regular:** [http://pt.wikipedia.org/wiki/Express%C3%A3o\\_regular](http://pt.wikipedia.org/wiki/Express%C3%A3o_regular)

## +info

**Expressões regulares com PHP e Python:**

<http://blog.rafaelcapucho.com/expressoes-regulares/expressoes-regulares-com-php-e-python-na-pratica.html>

**Expressões regulares com Ruby:**

[http://wiki.cercomp.ufg.br/Equipe\\_Web/RoR/Express%C3%A3o\\_Regular](http://wiki.cercomp.ufg.br/Equipe_Web/RoR/Express%C3%A3o_Regular)

**Mini-Curso de Expressões Regulares:**

<http://www.brasiltech.net/informatiquez/2008/04/09/mimi-curso-de-expressoes-regulares-entenda-como-funciona-parte-1/>

**Exemplos do livro Expressões Regulares:**

<http://www.piazinho.com.br/exemplos.html>

A stack of several books in various colors (dark blue, brown, green, and grey) is shown. The word "Obrigado" is written in a large, white, sans-serif font across the center of the stack. The background is a dark, solid color.

**Obrigado**